INF6303
DEVOIR 2
Spark distribué : analyse, MLlib et montée en échelle

Énoncé étudiant - travail en équipe

Prof. Ndah Daniel Yapi, Ph.D.
Université du Québec en Outaouais
Automne 2026

1. Mandat

Une boutique en ligne veut transformer son historique transactionnel en segments clients et en recommandations personnalisées.

- Construire un pipeline reproductible avec DataFrames, Spark SQL et MLlib.
- Justifier les choix de préparation, de modèle et d'évaluation.
- Démontrer l'exécution distribuée avec 1 puis 3 workers.
- Remettre un rapport de 6 à 8 pages, le code, les deux JSON et les captures Spark UI.

> Périmètre
> Le devoir couvre les semaines 4 à 9. Kafka et Structured Streaming sont exclus et seront mobilisés plus tard dans le projet de session.

2. Données et règles

Fichier	Contenu	Volume approximatif
transactions.csv.gz	Achats, quantités, prix et dates	198 000 lignes + anomalies
clients.csv.gz	Région et date d'inscription	12 000 clients
catalogue.csv	Catégorie et marque	800 produits

- Utiliser uniquement les données fournies; ne pas modifier les fichiers sources.
- Définir des schémas explicites; nettoyer doublons, identifiants manquants, quantités et prix invalides.
- Conserver 24 partitions pour les deux expériences de montée en échelle.
- Toute valeur présentée doit pouvoir être reliée au code ou au JSON produit.

> Intégrité
> Le manifeste donne les volumes physiques, mais la qualité du nettoyage doit être démontrée par vos propres contrôles Spark.

3. Partie A - Spark SQL et préparation (20 points)

- Lire les trois sources avec des schémas explicites et documenter les anomalies retirées.
- Joindre transactions et catalogue; expliquer le choix éventuel d'un broadcast join.
- Construire par client : récence au 1er novembre 2026, fréquence, montant et diversité de catégories.
- Avec une fenêtre, déterminer le produit générant le plus grand montant dans chaque région.
- Relever rdd.getNumPartitions(), puis expliquer pourquoi les DataFrames sont préférés aux RDD pour ce pipeline.
- Présenter un plan explain('formatted') et identifier au moins une transformation étroite et une transformation large.
- Justifier la logique du plan; une suite de captures sans explication ne suffit pas.

4. Partie B - Segmentation K-Means (25 points)

- Assembler et standardiser les quatre caractéristiques RFM étendues.
- Comparer K=2, 3, 4, 5 et 6 avec coût et silhouette.
- Choisir K en combinant métrique, stabilité et interprétabilité.
- Profiler chaque cluster avec les variables originales et proposer un nom métier.
- Expliquer pourquoi le coût d'entraînement ne peut pas, seul, sélectionner K.

K	Coût	Silhouette	Décision
2			
3			
4			
5			
6			

5. Partie C - Recommandation ALS (25 points)

- Construire les triplets (client_id, produit_id, strength) à partir des quantités.
- Créer une séparation reproductible entraînement/test et prévenir les fuites de données.
- Entraîner ALS en mode implicite; documenter rank, maxIter, regParam et alpha.
- Retirer les produits déjà vus avant le Top-10.
- Calculer Recall@10 et expliquer le cold start.
- Comparer deux configurations ALS en ne modifiant qu'un ensemble limité de paramètres.

> Attention
> Une recommandation pertinente n'est pas une classification correcte. Recall@10 porte sur le classement des articles pertinents du jeu de test.

6. Partie D - Distribution et montée en échelle (20 points)

```
.\scripts\executer_devoir2.ps1 -Workers 1 -Partitions 24
.\scripts\executer_devoir2.ps1 -Workers 3 -Partitions 24
```

- Vérifier que master vaut spark://spark-master:7077, jamais local[*].
- Fournir une capture montrant trois workers ALIVE et une capture d'un stage avec plusieurs tasks.
- Comparer les durées totales et, si disponibles, les durées K-Means et ALS.
- Calculer le speedup T1/T3 et expliquer pourquoi il peut rester inférieur à 3.
- Identifier un shuffle et relier ses lectures/écritures à une opération du code.

7. Remise et barème

Élément	Points
Spark SQL et préparation	20
K-Means	25
ALS et Top-10	25
Distribution et montée en échelle	20
Reproductibilité, clarté et français	10
Total	100

- Rapport PDF de 6 à 8 pages, hors annexes.
- Dossier src complété; aucun notebook contenant seulement des sorties.
- resultat_1_worker.json et resultat_3_workers.json.
- Deux captures Spark UI légendées.
- Travail effectué dans les mêmes équipes que le devoir 1; date de remise communiquée sur Moodle.