Devoir 2 - Spark distribué

Partie P1 | Chargement et nettoyage des données

A.1. Chargement et préparation des données

La première étape du projet consiste à préparer les données transactionnelles nécessaires à la segmentation des clients et au système de recommandation. Cette préparation est réalisée avec PySpark, à l'aide de DataFrames et de schémas explicites (StructType), afin de garantir la cohérence des types et la reproductibilité du traitement.

Trois fichiers sont utilisés :

Fichier	Contenu	Volume initial
transactions.csv.gz	Transactions, clients, produits, dates, quantités et prix	198 350
clients.csv.gz	Identifiants clients, régions et dates d'inscription	12 000
catalogue.csv	Identifiants produits, catégories et marques	800

Les identifiants des clients et des produits sont conservés sous forme entière (IntegerType) pour faciliter les jointures et leur utilisation ultérieure dans le modèle de recommandation ALS.

A.2. Nettoyage et contrôle de qualité

La fonction charger_et_nettoyer() effectue successivement les opérations suivantes :

• Suppression des doublons exacts à l'aide de dropDuplicates().

• Exclusion des transactions contenant des identifiants ou des dates manquants.

• Suppression des transactions dont la quantité ou le prix unitaire est inférieur ou égal à zéro.

• Vérification des champs obligatoires dans les fichiers clients et catalogue.

• Détection des transactions faisant référence à des clients ou produits absents des tables correspondantes.

Les références clients et produits inexistantes sont signalées dans l'audit, sans être automatiquement supprimées.

Les contrôles préliminaires réalisés sur les données fournies indiquent 350 doublons exacts et un volume attendu de 197 677 transactions valides. Ces effectifs restent à confirmer par l'exécution du pipeline Spark.

A.3. Partitionnement et reproductibilité

Après nettoyage, les transactions sont redistribuées selon leur identifiant client avec la commande :

`repartition(partitions, "client_id")`

Le nombre de partitions est fixé à 24 pour les deux configurations expérimentales, conformément aux consignes. Cette répartition par client facilite également certaines opérations d'agrégation ultérieures.

Enfin, un audit automatique affiche les volumes avant et après nettoyage, les principales anomalies, les références manquantes et le nombre de partitions.

Les fichiers sources restent inchangés. La fonction retourne trois DataFrames nettoyés, directement réutilisables pour les analyses Spark SQL, la segmentation K-Means et les recommandations ALS.